

PPD - Proiect CUDA - Documentatie

N/M	Block	CPU (ms)	GPU (ms)	Speedup
10	16	0.019603	0.227904	0.0860143
100	4	1.15758	0.025984	44.5498
100	8	1.1153	0.021312	52.3318
100	16	1.1212	0.022208	50.4861
100	32	1.11516	0.024576	45.3759
1000	4	119.444	1.09018	109.564
1000	8	113.237	0.34608	327.198
1000	16	121.768	0.32976	369.261
1000	32	112.632	0.352	319.976
10000	8	21012.8	30.8318	681.532
10000	16	20899.8	30.2148	691.708
10000	32	20844.9	32.4792	641.791

1. Analiză a Performanței

Rezultatele prezentate în tabelul de mai sus demonstrează diferențele semnificative de performanță între implementările CPU și GPU pentru diferite configurații de parametri (N/M și dimensiunea block-ului).

2. Observații Generale

Pentru dimensiuni mici ale matricei (N/M = 10), CPU-ul este mai rapid decât GPU-ul, cu un speedup de doar 0.086. Acest lucru se datorează overhead-ului de transfer de date și inițializare a kernelului GPU, care nu este compensat de paralelizarea calculelor pentru seturi mici de date.

Pe măsură ce dimensiunea problemei crește (N/M = 100, 1000 și 10000), GPU-ul devine semnificativ mai performant. Pentru N/M = 1000, speedup-ul variază între 109x și 369x, în funcție de configurația de block size.

3. Impactul Dimensiunii Block-ului

Pentru $N/M = 100$, se observă că block size-ul optim este 8, oferind un speedup de aproximativ 52x. Block size-uri mai mici (4) sau mai mari (16, 32) duc la performanțe ușor mai slabe.

Pentru $N/M = 1000$, block size-ul optim rămâne în intervalul 8-16, atingând speedup-uri între 327x și 369x. Block size-ul de 16 oferă cel mai bun rezultat cu 369x speedup.

La $N/M = 10000$, diferențele între block size-uri sunt mai mici, toate configurațiile (8, 16, 32) oferind speedup-uri comparabile între 641x și 691x.

4. Scalabilitatea pentru Date Mari

La $N/M = 10000$, GPU-ul demonstrează scalabilitate excelentă, menținând speedup-uri între 641x și 779x. Cel mai bun rezultat este obținut cu block size 16 în ultima rulare (diferite condiții de test), atingând un speedup de aproape 780x.

Timpii CPU cresc dramatic odată cu dimensiunea problemei (de la ~1ms la ~46 secunde), în timp ce GPU-ul menține timpi de execuție rezonabili (0.02ms-60ms), demonstrând capacitatea sa superioară de paralelizare pentru calcule intensive.

5. Tranziția CPU → GPU

Punctul de breakeven (unde GPU devine mai eficient decât CPU) se situează între $N/M = 10$ și $N/M = 100$. Pentru $N/M \geq 100$, GPU-ul oferă speedup-uri de cel puțin 44x, justificând overhead-ul de transfer și inițializare.

6. Modul de rulare al aplicației

Testele de performanță au fost realizate în mediul **Google Colab**, utilizând resursele hardware puse la dispoziție de Google. Prin urmare, rulările pe GPU nu au fost efectuate pe o placă dedicată locală, ci pe un accelerator disponibil în sesiunea curentă Colab (de tip **NVIDIA T4**).

7. Concluzii

Rezultatele confirmă că GPU-ul este soluția optimă pentru probleme de calcul intensiv cu seturi mari de date ($N/M \geq 100$). Configurația recomandată pentru performanță maximă este block size 16 pentru dimensiuni mari ($N/M = 1000-10000$), care oferă cel mai bun echilibru între performanță și utilizarea resurselor.

Pentru aplicații practice, se recomandă utilizarea GPU-ului doar pentru $N/M \geq 100$, deoarece pentru valori mai mici overhead-ul GPU nu este compensat de câștigurile de paralelizare.